

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

เว็บไซต์วิเคราะห์ความเป็นไปได้ของค่าเงินฟอเร็กซ์ ซึ่งเป็นเว็บไซต์ที่ช่วยในการวิเคราะห์และพยากรณ์ทิศทางค่าเงินว่าจะเป็นไปในทิศทางทางใด โดยนำชุดข้อมูลและสถิติของค่าเงินมาใช้เป็นชุดข้อมูลในการเรียนรู้ โดยผู้วิจัย ได้ทำการศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง ดังนี้

2.1 การเตรียมข้อมูล (Data Preparation)

การเตรียมข้อมูล หมายถึง กระบวนการใด ๆ ที่จำเป็นต้องทำกับข้อมูลดิบ (Raw Data) ที่ได้รับมาเพื่อปรับเปลี่ยนข้อมูลให้อยู่ในรูปแบบที่เหมาะสมที่จะนำไปโหลดเข้าฐานข้อมูล หรือนำไปวิเคราะห์ต่อไปความหมายที่เจาะจงของการเตรียมข้อมูลอาจจะแตกต่างกันไปสำหรับแต่ละระบบผลลัพธ์การประมวลผลของระบบหนึ่ง อาจกลายมาเป็นข้อมูลดิบของระบบต่อไป

พิจารณาการเตรียมข้อมูลเป็นระบบอย่างหนึ่งที่มีอินพุตเป็นข้อมูลดิบและมีเอาต์พุตเป็นข้อมูลที่อยู่ในรูปแบบที่พร้อมนำไปใช้งานต่อไปได้ทันที โดยมากแล้วการนำข้อมูลไปใช้งานต่อมักจะเป็นการนำไปโหลดเข้าฐานข้อมูลหรือนำไปวิเคราะห์หาคำตอบอย่างใดอย่างหนึ่งอาจเรียกกระบวนการนี้ว่าการทำความสะอาดข้อมูล ซึ่งก็ให้ความหมายคล้ายคลึงกัน (ปัญญาส เปี่ยมสุข 11 June 2014:Online)

2.2 รากที่สองของค่าความคลาดเคลื่อนเฉลี่ยกำลังสอง (Root Mean Square- Error)

รากที่สองของค่าความคลาดเคลื่อนเฉลี่ยกำลังสอง (Root Mean Square Error: RMSE) เป็นค่าที่ใช้ในการวัดขนาดของความคลาดเคลื่อนของการพยากรณ์ โดยค่าดังกล่าวได้จากค่าความคลาดเคลื่อนกำลังสองเฉลี่ย (Mean Square Error: MSE) ซึ่งเป็นการนำผลต่างของค่าจริงและผลลัพธ์จากการพยากรณ์ยกกำลังสอง อย่างไรก็ตามถ้าค่าผลต่างมีค่ามาก (ฐิติ ยามซุง 2 June 2016 :Online) จะส่งผลให้ค่าความคลาดเคลื่อนมีค่าที่สูงจึงมีการนำค่าดังกล่าวมาคำนวณด้วยรากที่สอง (Square Root) เพื่อให้ค่าดังกล่าวมีหน่วยวัดเดียวกับค่าที่ทำการทดลองในกรณีค่ารากที่สองของค่าความคลาดเคลื่อนเฉลี่ยกำลังสองที่ได้จากการทดลองมีค่าน้อยจะแสดงให้เห็นว่าตัวแบบการพยากรณ์สามารถทำนายผลลัพธ์ที่มีความคลาดเคลื่อนที่ต่ำหรือกล่าวได้ว่าแบบจำลองการพยากรณ์มีประสิทธิภาพที่ดีค่ารากที่สองของค่าความคลาดเคลื่อนเฉลี่ยกำลังสองสามารถคำนวณได้จากสมการที่ (2.1)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \quad (2.1)$$

เมื่อ Y_i คือค่าจริงที่ใช้ในการสร้างแบบจำลอง
 Y คือค่าประมาณการจากแบบจำลองการพยากรณ์
 n คือจำนวนชุดข้อมูลในชุดข้อมูล

2.3 ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Error)

ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Error: MAE) เป็นค่าเฉลี่ยของ ความแตกต่างสัมบูรณ์ระหว่างค่าพยากรณ์และค่าจริงหากค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAE) มีค่าน้อยแสดงว่าแบบจำลองสามารถประมาณค่าประมาณได้ใกล้เคียงกับค่าจริงค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Jame Justbe.23 Mar 2016:Online) สามารถคำนวณได้จากสมการที่ (2.2)

$$MAE = \frac{1}{n} \sum_{i=1}^n (Y_i - Y) \quad (2.2)$$

การประมาณค่าความแม่นยำ (Evaluation Criterion) จากวิธีต่าง ๆ ที่สร้างขึ้น แบบจำลองที่สร้างขึ้นต้องมีความแม่นยำเข้ากันได้กับข้อมูลที่ใช้ในการสร้างแบบจำลองนั้นสูงสุด (Model Best Fit) แบบจำลองนี้จะถูกนำไปทดสอบกับกลุ่มข้อมูลชุดที่ทราบค่าจริง (Actual Data) ผลจากการพยากรณ์ข้อมูลชุดใหม่ (Predicted Data) จะถูกนำมาคำนวณหาความคลาดเคลื่อนสัมพัทธ์ (Magnitude of Relative Error: MRE) โดยสามารถคำนวณได้จากสมการที่ (2.3) (Anne Marie Helmenstine 29 Sep 2018: Online)

$$MRE = \frac{|Actual_i - Predicted_i|}{Actual_i} \quad (2.3)$$

หากข้อมูลมีจำนวนมากต้องนำมาหาค่าเฉลี่ยความคลาดเคลื่อนสัมพัทธ์ (Mean Magnitude of Relative Error: MMRE) โดยที่ค่าเฉลี่ยความคลาดเคลื่อนสัมพัทธ์มีค่าสูงหมายถึงเปอร์เซ็นต์ของความคลาดเคลื่อนสูงถ้าค่าเฉลี่ยความคลาดเคลื่อนสัมพัทธ์มีค่าน้อยหมายถึงการพยากรณ์ที่ได้มีความแม่นยำสูง (atorn.28 Mar 2016:Online) โดยสามารถคำนวณได้จากสมการที่ (2.4)

$$MMRE = \frac{1}{n} \sum_{i=1}^n \frac{|Actual_i - Predicted_i|}{Actual_i} \times 100 \quad (2.4)$$

2.4 เพื่อนบ้านใกล้เคียง (K-Nearest Neighbors)

ปัจจุบันมีนักวิจัยหลายกลุ่มได้พยายามจัดการข้อมูลที่มีค่าสูญหาย การแทนค่าข้อมูลที่สูญหาย ด้วยวิธีต่าง ๆ เพื่อนบ้านใกล้เคียงเป็นอัลกอริทึมหนึ่งที่ถูกนำมาประยุกต์ใช้หาความสัมพันธ์ระหว่างกลุ่มข้อมูลที่จะนำมาประมาณค่าที่สูญหายกับข้อมูลที่มีค่าสูญหายดังสมการ (2.5)

$$\text{dist}(X_q, X_i) = \sqrt{(\sum_{k=1}^n ((X_{q,k}) - (X_{i,k})))^2} \quad (2.5)$$

$\text{dist}(X_q, X_i)$ คือระยะห่างระหว่างตัวอย่าง x_q กับตัวอย่าง x_i คือคุณสมบัติทั้งหมดของตัวอย่าง $x_{i,k}$ คือคุณสมบัติตัวที่ k ของตัวอย่าง x_i และประมาณค่าข้อมูลสูญหายด้วยสมการดังนี้ (2.6)

$$\hat{a}_j(X_q) = \frac{\sum_{i=1}^k a_j(X_i)}{k} \quad (2.6)$$

$\hat{a}_j(X_q)$ คือค่าประมาณของลักษณะประจำ (Attribute) j ของตำแหน่ง X_q เมื่อต้องการประมาณค่าเพื่อแทนข้อมูลที่มีค่าสูญหายจะมีการดำเนินการดังนี้ (saed sayad.15 June 2018:Onlin)

- 1) กำหนดค่า K
- 2) คำนวณหาความสัมพันธ์ระหว่างกลุ่มที่จะนำมาประมาณค่าสูญหายและกลุ่มข้อมูลสูญหาย ด้วยวิธีการระยะทางแบบยุคลิดดังสมการ (2.5)
- 3) เลือกค่าที่มีระยะห่างกับค่าสูญหายน้อยที่สุดมา k ตัว
- 4) ประมาณค่าข้อมูลสูญหายด้วยการหารด้วยค่า k ดังสมการที่ (2.6)

2.5 ต้นไม้ตัดสินใจ (Decision Tree)

ต้นไม้ตัดสินใจ (Decision Tree) คือ แบบจำลองทางคณิตศาสตร์ที่ใช้ในการหาทางเลือกที่ดีที่สุด โดยการนำข้อมูลมาสร้างแบบจำลองการพยากรณ์ในรูปแบบของโครงสร้างต้นไม้ ซึ่งมีการเรียนรู้ข้อมูลแบบมีผู้สอน (Supervised Learning) ต้นไม้การตัดสินใจสามารถสร้างแบบจำลอง ได้ทั้งการถดถอย (regression) และ การจำแนกข้อมูล (classification) ในรูปแบบโครงสร้างของต้นไม้ (saed sayad. 15 June 2018:Online) โดยทำการแบ่งชุดข้อมูลออกเป็นชุดย่อย ๆ ที่เล็กลงประกอบไปด้วย โหนดปลาย หรือผลลัพธ์ที่เป็นไปได้ (Decision Nodes) ใบ (leaf nodes) ราก (Root) อัลกอริทึม ต้นไม้การตัดสินใจ สามารถใช้สร้างแผนผังการตัดสินใจสำหรับการทำการถดถอย โดยใช้ค่าความเบี่ยงเบนมาตรฐาน (Standard Deviation : SD) ดังสมการ (2.7) ค่าส่วนเบี่ยงเบนมาตรฐานสำหรับค่าลักษณะประจำทั้ง 2 ค่าดังสมการ (2.8) และการลดความเบี่ยงเบนมาตรฐานดังสมการ (Standard Deviation Reduction: SDR) ดังสมการที่ (2.9)

$$S(T) = \sqrt{\frac{\sum (x - \bar{x})^2}{n}} \quad (2.7)$$

$$S(T, X) = \sum_{c \in X} P(c) S(c) \quad (2.8)$$

$$SDR(T, X) = S(T) - S(T, X) \quad (2.9)$$

2.6 โครงข่ายประสาทเทียม (Artificial Neural Networks)


โครงข่ายประสาทเทียม (Artificial Neural Network: ANN) เป็นวิธีที่ถูกพัฒนามาจากการทำงานของเซลล์ประสาททางชีววิทยา (Biological Neuron) ซึ่งมีความสามารถในการปรับตัวเมื่อข้อมูลไม่เป็นเชิงเส้นมีความสามารถในการเรียนรู้จากตัวอย่างและการทำให้เป็นแบบทั่วไป (Generalize) (Engkarat Techapanurak.22 Apr 2018:Online)

โครงข่ายจะถูกฝึกการเรียนรู้โดยการแสดงรูปแบบ (Pattern) ต้องการให้โครงข่ายเรียนรู้ด้วยกฎการเรียนรู้ (Learning Rule) การที่โครงข่ายถูกทำให้เป็นกรณีทั่วไปจะทำให้ตัวโครงข่ายสามารถที่จะจำแนกรูปแบบของข้อมูลนั้นเข้าแบบใหม่ ๆ ที่ตัวโครงข่ายไม่รู้จักมาก่อนในระดับที่เป็นที่ยอมรับได้ ตัวโครงข่ายจะทำการเก็บข้อมูลความรู้ (Knowledge) ในระหว่างขั้นตอนของการเรียนรู้โดยเก็บไว้ที่น้ำหนักประสาท (Synaptic Weights) ส่วนประกอบหลักของ Neural Network

1) ข้อมูลอินพุต (Input Layer) ที่ชั้นนี้จะเป็นข้อมูลอินพุตจำนวนของโหนดขึ้นอยู่กับจำนวนของอินพุต

2) ชั้นซ่อน (Hidden Layers) เป็นชั้นที่อยู่ระหว่างกลางซึ่งจะมีผลอย่างมากต่อประสิทธิภาพในการเรียนรู้ของโมเดล ซึ่งส่วนนี้จะส่งผลต่อโมเดลมากที่สุด

3) ผลลัพธ์ (Output Layer) เป็นชั้นที่จะนำเอาข้อมูลจากการคำนวณไปใช้จำนวนของโหนดในชั้นนี้ขึ้นอยู่กับรูปแบบของผลลัพธ์ที่เราจะนำไปใช้ ถ้าเป็นการถดถอยจะกำหนดให้ชั้นของผลลัพธ์เป็นแบบโหนดเดียวเพราะต้องการคำตอบเพียงค่าเดียวแสดงดังรูปที่ 2.1



รูปที่ 2.1 สถาปัตยกรรมโครงข่ายประสาทเทียมแบบชั้นเดียวหนึ่งนิวรอน

การเรียนรู้ของโครงข่ายประสาทเทียมแบบแพร่ย้อนกลับจะสามารถหาผลลัพธ์ของชั้นซ่อนก่อนทำการการปรับค่าได้ดังสมการที่ (2.10)

$$S_m = \sum_{n=1}^N x_n * w_{nm} \quad (2.10)$$

ค่าเอาต์พุตของชั้นซ่อนหลังทำการปรับค่าดังสมการที่ (2.11)

$$y_m = f(s_m) \quad (2.11)$$

ฟังก์ชันที่ใช้ในการปรับค่า ($f(x)$) ประกอบด้วยสมการหลายสมการซึ่งแต่ละสมการก็จะให้ผลที่แตกต่างกันออกไปโดยในโครงงานวิจัยนี้เลือกเอาสมการ 2 สมการประกอบด้วยเลรู (ReLU) และ ซิกมอยด์ (Sigmoid) ดังสมการที่ (2.12) และ (2.13) ตามลำดับ

$$f(x) = \max(0, x) \quad (2.12)$$

$$f(x) = \frac{1}{1+e^{-x}} \quad (2.13)$$

2.7 อนุกรมเวลา (Time Series Data)

ข้อมูลอนุกรมเวลา (Time Series Data) ข้อมูลอนุกรมเวลาคือชุดข้อมูลที่รวบรวมและจัดเก็บตามลำดับต่อเนื่องกัน ภายใต้การเพิ่มขึ้นของเวลา (Reza Hoshmand. 23 Apr 2018:Online) โดยข้อมูลดังกล่าวจะถูกเก็บ รวบรวมอย่างต่อเนื่องในระยะเวลาติดต่อกันตามช่วงเวลาที่ต้องการ เช่น ข้อมูลราคาหุ้นในตลาดหลักทรัพย์ ข้อมูลปริมาณน้ำในเขื่อน ซึ่งจัดเก็บเป็นวันหรือตามความต้องการของผู้ใช้งานบางกรณีการจัดเก็บข้อมูลอาจมีลักษณะการจัดเก็บเป็นช่วงเวลาต่อเนื่องกันเช่นข้อมูลปริมาณการเกิดอุบัติเหตุในช่วงเทศกาลปีใหม่จะกำหนดเวลาเริ่มต้นในการจัดเก็บข้อมูลและกำหนดเวลาสิ้นสุดในการจัดเก็บข้อมูลเท่า ๆ กันทุกปี อย่างไรก็ตามการจัดเก็บข้อมูลอนุกรมเวลามีวัตถุประสงค์เพื่อการสร้างแบบจำลองในการทำนายปริมาณที่จะเกิดขึ้นในอนาคต (Time Series Model) โดยการวิเคราะห์อนุกรมเวลา (Time Series Analysis)

2.8 การวิเคราะห์อนุกรมเวลา (Times Series Analysis)

การวิเคราะห์อนุกรมเวลา (Times Series Analysis) คือ การทำนายปริมาณข้อมูลที่จะเกิดขึ้นในอนาคต ซึ่งอาศัยข้อมูลอนุกรมเวลาในอดีตเป็นเทคนิควิธีที่ได้รับความนิยมเป็นการศึกษาถึงความสัมพันธ์ระหว่างข้อมูลกับช่วงเวลาที่ผ่านมา ช่วงเวลาอาจหมายถึงวัน เดือน ไตรมาสหรือปี อย่างไรก็ตามการวิเคราะห์อนุกรมเวลาเพื่อการพยากรณ์ปริมาณข้อมูลที่จะเกิดขึ้นในอนาคตจำเป็นต้องวิเคราะห์ถึงความสัมพันธ์ต่าง ๆ ที่ขึ้นต่อกันของข้อมูล เช่น ส่วนของแนวโน้ม (Trend Component) ส่วนของฤดูกาล (Seasonal Component) ส่วนของวัฏจักร (Cyclical Component) และส่วนของเหตุการณ์ผิดปกติ (Irregular Component) จุดมุ่งหมายของการวิเคราะห์อนุกรมเวลา คือ วิเคราะห์หาตัวแปรที่เหมาะสมกับการสร้างแบบจำลองในการทำนาย (Time Series Model) ซึ่งค่าการพยากรณ์ดังกล่าว มีความเกี่ยวข้องกับข้อมูลในอดีต (Yanovitzky.25 Apr 2018:Online)

2.9 งานวิจัยที่เกี่ยวข้อง

(Safitri, S. Yusra, Hermawan, Ripmiation, Pradani, 2017, p. 2-3) สถิติและการคาดการณ์ฟอเรียซ์ด้วยแมชชีนเลินนิ่ง ขึ้นอยู่กับข้อมูลเชิงประจักษ์ งานวิจัยนี้ได้ใช้การคาดการณ์ตามชุดข้อมูลโดยใช้อัลกอริทึม 3 ชนิด คือ เอสตาร์ (ASTAR) ซัพพอร์ตเวกเตอร์แมชชีน (SVM) และพันธุกรรมกับโครงข่ายประสาทเทียม (GANN) ในการหาผลคาดการณ์ที่ใกล้เคียงกับชุดข้อมูลจริง โดยยึดหลักเกณฑ์การเปรียบเทียบคือ รากที่สองของความคลาดเคลื่อนเฉลี่ยกำลังสอง ในการหาผลคาดการณ์ระหว่างอัลกอริทึมบทสรุปงานวิจัยนี้พบว่าเอสตาร์และพันธุกรรมกับโครงข่ายประสาทเทียมมีข้อดีขึ้นอยู่กับช่วงระยะเวลาเอสตาร์ใช้ข้อมูลทางสถิติทำให้คำนวณง่ายและซัพพอร์ตเวกเตอร์แมชชีน มีการเลือกโมเดลที่ไม่เอนเอียงไปทางใดทางหนึ่ง

(Yoke Leng Yong, Yunli Lee, David Ngo, 2015, p. 2-3) การตรวจสอบการซื้อขายค่าเงินประจำวันของค่าเงินฟอเร็กซ์นักวิจัยและนักวิเคราะห์ทางการเงินพยายามที่จะอธิบายความผันผวนของราคา โดยศึกษาอย่างใกล้ชิดและทำความเข้าใจตลาดฟอเร็กซ์และเทรดเดอร์หวังว่าจะสามารถคาดการณ์และตอบสนองต่อการผันผวนของราคาการซื้อขายได้ ในบทความนี้มีการศึกษาทฤษฎีพื้นฐานที่มีรูปแบบการทำซ้ำภายใต้ข้อมูลชุดเวลาที่เป็นพื้นฐานทางเทคนิค ในงานวิจัยนี้ได้ใช้การคาดการณ์ตามชุดข้อมูลโดยใช้อัลกอริทึม 2 ชนิดคือ ซัพพอร์ตเวกเตอร์แมชชีน (SVM) และโครงข่ายประสาทเทียมซึ่งจุดเด่นของการใช้โครงข่ายประสาทเทียมสามารถคาดการณ์ได้มีความแม่นยำมากกว่าการใช้ซัพพอร์ตเวกเตอร์แมชชีน บทสรุปงานวิจัยนี้คือค่าเงินที่เกิดขึ้นซ้ำในอดีตจะเป็นการเกิดแบบสุ่มทำให้เราไม่สามารถคาดการณ์อัตราแลกเปลี่ยนเงินที่ผันผวนได้เลยถึงแม้ว่าค่าเงินที่เกิดขึ้นบางตัวจะสามารถคาดเดาได้แต่ก็ไม่สามารถคาดการณ์ได้ทั้งหมด

(Safitri, S. Yusra, Hermawan, Ripmiatin, Pradani, 2017, p. 2-3) เทคนิคการทำนายการใช้ข้อมูลหลายตัวและการแก้ไขปัญหาความสัมพันธ์: งานวิจัยนี้จะเป็นการหาผลการพยากรณ์จากสมการทางคณิตศาสตร์โดย การวิเคราะห์ทางเทคนิคเป็นวิธีการคาดการณ์ตลาดราคาได้อย่างรวดเร็ว ข้อมูลเป็นตัวแปรสำคัญในการทำนายอนาคตโดยตัวแปรปกติที่ใช้ในการคำนวณจะมีราคาเปิด ราคาปิด ราคาสูง ราคาต่ำ มีหลายวิธีทางเทคนิคในการวิเคราะห์และคาดการณ์แนวโน้มโดยใช้คู่ราคาความสัมพันธ์ชนิดหนึ่ง บทความนี้เสนอวิธีการคาดการณ์และการวิเคราะห์โดยการเปรียบเทียบหลายคู่เพื่อวัดความแรงโดยใช้ระบบสนับสนุนการตัดสินใจในการวิเคราะห์ความสัมพันธ์ ข้อมูลการคำนวณเหล่านี้ส่งผลให้การคาดการณ์มีความถูกต้องมากขึ้น บทสรุปของบทความนี้พบว่าการคาดการณ์มีความถูกต้องมากขึ้นแต่ต้องดูสัญญาณของความแรงของค่าเงินในช่วงเวลาแต่ละวัน

(Mahsa Kangarani Farahani, 2015, p. 4-7) การเปรียบเทียบระหว่างเครือข่ายประสาทเทียมและเครือข่ายแบบเลื่อนสำหรับการคาดการณ์ราคาทองคำโดยงานวิจัยนี้ใช้การเปรียบเทียบของโครงข่ายประสาทเทียม (ANN) สำหรับทำนายระบบจริงของราคาทองคำ บทความนี้ได้เปรียบเทียบโมเดลแบบไฮบริดซึ่งเป็นค่าเฉลี่ยถ่วงน้ำหนักของโครงข่ายประสาทเทียม และแบบจำลองอนุกรมพีชซี วัตถุประสงค์หลักคือการทำนายราคาทองคำในตลาด โดยใช้โมเดล โครงข่ายประสาทเทียม และอนุกรมพีชซี บทสรุปของบทความนี้พบว่าโครงข่ายประสาทเทียม สามารถคาดการณ์ลาเบลที่เป็นตัวเลขได้และมีการทำนายสูงกว่าแบบจำลองอนุกรมพีชซี และแบบจำลองอนุกรมพีชซีการนำเอาโครงข่ายประสาทเทียมมาใช้ร่วมกับฟังก์ชันโลจิกทำให้การทำนายแม่นยำยิ่งขึ้น

(Safitri, S. Yusra, Hermawan, Ripmiatin, Pradani, 2017, p. 2-3) กลยุทธ์การซื้อขายแบบอัจฉริยะของฟอเร็กซ์เอ็นชานเซอร์โดยงานวิจัยนี้ได้กล่าวไว้ว่า ตลาดแลกเปลี่ยนเงินตราต่างประเทศ (Forex) คือ ตลาดการเงินที่ใหญ่ที่สุดในโลกที่มีการซื้อขายรายวันสูงสุดพฤติกรรมการซื้อขายที่ซับซ้อนจะเห็นในช่วงเวลาตลาดเปิดกว้างและเข้าใจรูปแบบแนวโน้มของตลาดการแก้ปัญหาจำนวน

มหาศาลเกี่ยวกับการทำนายและการตัดสินใจหลายคนมักจะเขียนกลยุทธ์รูปแบบการซื้อขายเพื่อระบุรูปแบบที่สำคัญที่พวกเขารู้จักแนวคิดเกี่ยวกับการซื้อขายอัตโนมัติหรืออัลกอริทึมการค้าขายแต่การสร้างอัลกอริทึมแบบผสมผสานนั้นค่อนข้างท้าทายจนกว่าจะมีคนมาแนะนำและปรับปรุงอัลกอริทึม บทความนี้จะเสนอความคิดที่สร้างสรรค์ของระบบที่เรียกว่าเกนนิบัก (Genibux) จะช่วยให้ผู้ค้าปรับปรุงกลยุทธ์ระบบจะแนะนำการปรับปรุงอัลกอริทึมด้วยเหตุผลเพื่อประโยชน์สูงสุดของกำไรจะขึ้นอยู่กับหลักการประมวลผลเหตุการณ์ที่ซับซ้อน

2.9 สรุปทฤษฎีและงานวิจัยที่เกี่ยวข้อง

จากการที่ได้ศึกษาทฤษฎีและค้นคว้างานวิจัยที่เกี่ยวข้อง ผู้จัดทำสามารถนำเอาทฤษฎีและงานวิจัยที่เกี่ยวข้องมาปรับใช้กับการวิเคราะห์ความเป็นไปได้ของค่าเงิน โดยนำเอาเทคนิคและวิธีต่างๆ มาปรับใช้ในการพยากรณ์การออกแบบหน้าจอบริษัท การออกแบบระบบการทำงานทั้งหมด เป็นต้น นอกจากนี้ทฤษฎีและงานวิจัยที่เกี่ยวข้องสามารถช่วยพัฒนาเว็บไซต์ได้สะดวกและรวดเร็วเพิ่มมากขึ้น